



Sono ao Volante - previsão e detecção de estados do sono




Contexto

O sono é um factor importante tanto na saúde como na produtividade das pessoas.

Um boa noite de sono leva a:

- Maiores níveis de concentração
- Maior produtividade
- Melhor recuperação do sistema motor
- Menor cansaço durante o dia

Falta de sono, porém, pode levar a consequências graves, tanto na saúde como a nível comportamental, especialmente quando é cumulativo.



Contexto

Conduzir é uma tarefa essencial na vida de muita gente mas exige:

- atenção máxima na estrada
- rapidez de pensamento para tomada de decisões

Acidentes de viação representam mais de 1.2 milhões de mortes por ano e um número muito mais elevado de acidentes não fatais.

Acidentes causados por estados de sonolência representam **20% do total de acidentes** do mundo e a **maior causa de morte na estrada**.

Os mais suscetíveis a terem acidentes com esta causa são condutores que o fazem durante muitas horas do seu dia.




Motivação

Já existem várias ferramentas de **detecção de sonolência** através de câmaras, mas o estado de **sonolência** pode começar antes destas o detectarem e esse intervalo de tempo é mais que suficiente para **acontecer um acidente**.

Então o ideal seria:

- Utilizar essas tecnologias para se o condutor está a entrar neste estado
- Combinar com métodos que consigam prever se um condutor vai entrar neste estado

Estados do sono



O sono pode ser dividido em 2 tipos e 4 estados:

- **N1** - que corresponde ao tipo NREM (movimento não rápido dos olhos)
- **N2** - que corresponde ao tipo NREM
- **N3** - que corresponde ao tipo NREM
- **REM sleep** - que corresponde ao tipo REM (movimento rápido dos olhos)

O sono NREM corresponde a 3 estados, em que:

- N1 representa o **início do sono**
- N2 o corpo entra num **estado mais calmo e relaxado**
- N3 representa o **sono profundo**


Proposta

A nossa proposta e objetivos com este trabalho são:

- Procurar novos métodos para classificar de forma eficaz os estados de sono.
- Realizar experiências com redes neurais de memória de longo prazo.
- Implementar *hyper parameter tuning* no trabalho efetuado anteriormente.


Classificar as fases do sono de uma forma fiável através dos dados de impulsos biométricos (ECG).

Este trabalho é uma extensão do trabalho desenvolvido na tese de mestrado **Sono ao Volante - Machine Learning para Previsão e Detecção de Sonolência**.



Pré-processamento de dados

Consiste na sincronização dos dados recolhidos a partir de ECG e polissonografia, tendo como janela flutuante segmentos de 1.5, 2.5, 3.5, e 4.5 minutos, centrados em stages de 30 segundos, descartando os 30 segundos iniciais e finais.



Classificadores

Aos já previamente implementados :

- Random Forest (RF),
- Support Vector Classifier (SVC)
- K-nearest neighbors (KNN)
- Linear Discriminant Analysis (LDA)

foram feitas experiências com classificadores que utilizam técnicas mais recentes

- XGBoost (XGB)
- LightGBM (LBGM)

Também foi implementada uma rede neuronal com arquitectura LSTM.

Tarefa predictiva

Neste trabalho apenas utilizamos janelas de 4.5 minutos.

Prever em que fase do sono se encontra o sujeito. A experiência foi feita para prever 3 ou 4 estados do sono.

Três estados:

- NREM
- REM
- Acordado

Quatro estados:

- Leve
- Profundo
- REM
- Acordado

Foram utilizadas as seguintes métricas:

- Precisão
- Kappa
- Recall

Resultados Obtidos

Os melhores resultados foram obtidos utilizando RF, XGBoost e KNN, e conseguimos melhorar todos os resultados obtidos anteriormente com Hyperparameter tuning.

Os resultados foram significativamente melhores classificando apenas 3 estados de sono.

A abordagem de deep-learning (rede LSTM) não obteve resultados bons, mas promissores possivelmente para datasets mais completos.

UIT (10-VC)					4.5 min
Modelo	1.5 min	2.5 min	3.5 min	4.5 min	N: 0.8 (0.01) R: 0.65 (0.08) W: 0.79 (0.04)
SVM	0.75 (0.01)	0.77 (0.01)	0.79 (0.01)	0.79 (0.01)	N: 0.72 (0.01) R: 0.52 (0.07) W: 0.67 (0.02)
LDA	0.74 (0.01)	0.72 (0.01)	0.71 (0.01)	0.7 (0.01)	N: 0.71 (0.01) R: 0.74 (0.07) W: 0.82 (0.03)
KNN	0.69 (0.02)	0.7 (0.02)	0.72 (0.01)	0.73 (0.01)	N: 0.93 (0.01) R: 0.71 (0.07) W: 0.81 (0.05)
RF	0.84 (0.01)	0.87 (0.0)	0.89 (0.01)	0.9 (0.01)	

Method	Accuracy	Kappa	Recall
LighGBM	0.89 (0.01)	0.70 (0.03)	NREM = 0.90 (0.01) REM = 0.77 (0.06) WAKE = 0.87 (0.02)
XGBoost	0.91 (0.01)	0.73 (0.03)	NREM = 0.93 (0.01) REM = 0.76 (0.09) Wake = 0.81 (0.03)
RF	0.91 (0.01)	0.74 (0.02)	NREM = 0.93 (0.01) REM = 0.76 (0.07) Wake = 0.84 (0.03)
KNN	0.90 (0.01)	0.71 (0.02)	NREM = 0.92 (0.01) REM = 0.82 (0.06) Wake = 0.82 (0.03)
SVC	0.85 (0.01)	0.62 (0.02)	NREM = 0.86 (0.01) REM = 0.80 (0.06) Wake = 0.83 (0.03)
LDA	0.74 (0.02)	0.41 (0.03)	NREM = 0.76 (0.03) REM = 0.55 (0.11) Wake = 0.69 (0.03)

Conclusões

O dataset revelou ser demasiado limitado, tanto no número de sujeitos, como na quantidade de dados apresentados. Nas nossas experiências, apenas a abordagem de Sliding Window de 4.5 minutos foi considerado por ser o que obteve o resultado mais favorável em todas as experiências.

Pode ser realizado mais trabalho testando diferentes técnicas de oversampling e diferentes métodos de seleção de atributos.

Pode ser utilizado para integrar deteção de problemas de sono e sonolência na condução.

Obrigado pela atenção.

